

RAPPORT TECHNIQUE ACADÉMIQUE

Optimisation de la Maintenance Industrielle

par Apprentissage par Renforcement Profond (Deep RL)

Comparaison des stratégies **DQN** et **PPO** face aux méthodes traditionnelles.

Auteur :
Amine AMLLAL

Encadrant :
M. Tawfik MASROUR

Année Universitaire 2024-2025

Table des matières

1	Introduction	2
1.1	Contexte et Enjeux	2
2	Formulation du Problème (MDP)	3
2.1	Définition Formelle	3
2.2	Espace d'États $\mathcal{S}$	3
2.3	Espace d'Actions $\mathcal{A}$	3
2.4	Fonction de Transition $\mathcal{P}$	3
2.5	Fonction de Récompense $\mathcal{R}$ - DÉTAILLÉE	4
3	Algorithmes et Implémentation	5
3.1	Deep Q-Network (DQN)	5
3.2	Proximal Policy Optimization (PPO)	5
4	Résultats et Comparaison	6
4.1	Performance des Algorithmes	6
4.2	Comparaison avec les Méthodes Classiques	6
5	Conclusion et Perspectives	7

Chapitre 1

Introduction

1.1 Contexte et Enjeux

La maintenance des équipements critiques représente un enjeu économique majeur. Les approches traditionnelles (réactive, préventive) peinent à trouver l'équilibre optimal entre le coût d'intervention et le risque de panne. Ce projet propose une approche basée sur un agent intelligent autonome.

Objectif Principal

Développer un agent Deep RL capable de décider dynamiquement de la maintenance en maximisant le RUL (Remaining Useful Life) utilisé tout en minimisant les coûts.

Chapitre 2

Formulation du Problème (MDP)

2.1 Définition Formelle

Le problème est modélisé sous la forme d'un Processus de Décision Markovien $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$.

2.2 Espace d'États $\mathcal{S}$

L'agent observe une fenêtre glissante de capteurs pour percevoir la dynamique temporelle de la dégradation.

$$s_t = [x_{t-29}, x_{t-28}, \dots, x_{t-1}, x_t] \in \mathbb{R}^{420}$$

Où x_t est un vecteur de 14 capteurs physiques (vibrations, température, pression...).

2.3 Espace d'Actions $\mathcal{A}$

À chaque pas de temps t , l'agent choisit une action binaire :

$$\mathcal{A} = \{0(\text{Continuer}), 1(\text{Maintenance})\}$$

2.4 Fonction de Transition $\mathcal{P}$

La dynamique du système est déterministe pour la dégradation :

$$\text{RUL}_{t+1} = \begin{cases} \text{RUL}_{\max} & \text{si } a_t = 1 \\ \max(0, \text{RUL}_t - \Delta_t) & \text{si } a_t = 0 \end{cases}$$

où la dégradation Δ_t est modélisée par :

$$\Delta_t = \beta_{base} + \epsilon_t + \beta_{accel} \cdot \left(1 - \frac{RUL_t}{RUL_{max}}\right)^{1.5}$$

avec $\beta_{base} = 1.0$, $\epsilon_t \sim \mathcal{N}(0, 2.5)$, et $RUL_{max} = 125$ cycles.

2.5 Fonction de Récompense $\mathcal{R}$ - DÉTAILLÉE

Composante Centrale

La fonction équilibre trois objectifs critiques : maintenir la production, minimiser les coûts d'intervention et éviter absolument la panne.

$$r_t = \begin{cases} +1.0 & \text{si } a_t = 0 \text{ et } RUL_t > 0 \\ -(50 + 0.5 \cdot RUL_t) & \text{si } a_t = 1 \\ -200 & \text{si } RUL_t \leq 0 \end{cases}$$

Le coût de maintenance variable est défini par :

$$C_{maint}(RUL_t) = C_{fixed} + \alpha \cdot RUL_t$$

Paramètre	Valeur	Justification
$r_{running}$	+1.0	Bonus fonctionnement normal
C_{fixed}	50 €	Coût fixe de maintenance
α	0.5	Pénalité pour RUL gaspillé
$C_{failure}$	200 €	Coût de panne catastrophique

TABLE 2.1 – Paramètres de la fonction de récompense

Résultat Clé

Justification de la stratégie :

1. Le terme $\alpha \cdot RUL_t$ pénalise une maintenance trop précoce.
2. $C_{failure} > C_{maint}$ encourage fortement la prévention.
3. $r_{running}$ incite à maximiser la durée de vie opérationnelle.

Chapitre 3

Algorithmes et Implémentation

3.1 Deep Q-Network (DQN)

DQN utilise un réseau de neurones pour approximer la fonction de valeur $Q(s, a)$.

- **Architecture** : MLP ($420 \rightarrow 256 \rightarrow 256 \rightarrow 2$).
- **Spécificité** : Utilisation d'un *Replay Buffer* de 10,000 transitions.

3.2 Proximal Policy Optimization (PPO)

PPO est une méthode *Policy-Gradient* qui optimise directement la politique π_θ . Il s'est avéré plus stable pour ce problème de contrôle continu.

- **Architecture** : Actor-Critic.
- **Avantage** : Mises à jour prudentes ("Clipping") évitant la divergence.

Chapitre 4

Résultats et Comparaison

4.1 Performance des Algorithmes

L'entraînement a été réalisé sur 100,000 pas de temps. PPO a montré une convergence plus rapide et plus stable que DQN.

Algorithme	Coût Moyen	Taux Panne	RUL Utilisé	Temps Entr.
DQN	72 €	3%	88%	120s
PPO	65 €	2%	92%	95s

TABLE 4.1 – Comparaison PPO vs DQN (Moyenne sur 100 épisodes)

4.2 Comparaison avec les Méthodes Classiques

L'agent PPO a ensuite été confronté aux stratégies industrielles standards sur une simulation longue durée (2000 cycles).

Stratégie	Coût Total	Panne	RUL Utilisé	Rang
Maintenance Périodique	140 €	5%	45%	3
Maintenance à Seuils	100 €	2%	70%	2
IA (PPO)	65 €	2%	92%	1

Résultat Clé

Impact Industriel : L'approche par Deep RL (PPO) permet de **réduire les coûts de maintenance de 53%** par rapport à une approche périodique, tout en maximisant l'utilisation de la durée de vie des composants (92%).

Chapitre 5

Conclusion et Perspectives

Ce travail valide l'efficacité du Deep Reinforcement Learning pour la maintenance prédictive. L'agent autonome apprend une politique complexe qui surpasse les règles heuristiques humaines. Les perspectives incluent le test sur des données réelles (NASA C-MAPSS) et l'intégration dans un système SCADA industriel.